

데이터·개념 기초

머신러닝이 뭔지부터 데이터 유형·지도/비지도·특성/타겟·차원까지. 1~7절.

머신러닝 실습은 결국 "하나의 뼈대를 데이터만 바꿔 반복"합니다.

데이터 로드 → 살펴보기 → 전처리 → 분할 → 학습 → 평가 → 예측

Q1 머신러닝이란

머신러닝 = 사람이 규칙을 일일이 코딩하는 대신, 데이터로 규칙을 스스로 배우게 하는 것. 배운 규칙(= 모델)으로 새 데이터의 답을 예측합니다.

쉽게 — 전통 프로그래밍은 레시피를 사람이 써 주는 것("소금 한 스푼, 3분 끓이기"). 머신러닝은 반대로 완성된 요리를 수천 접시 맛보여 주고 레시피를 알아내게 하는 것. 그래서 데이터(재료)와 정답(완성 요리)이 둘 다 필요하고, 나온 레시피가 곧 모델입니다.

전통 프로그래밍

규칙(사람이 씀) + 데이터



답

머신러닝

데이터 + 답



규칙(모델)

방향이 거꾸로! ML은 데이터+답으로 규칙을 만들어 냅니다.

AI ⊃ 머신러닝 ⊃ 딥러닝 — 딥러닝은 머신러닝의 한 갈래, 머신러닝은 인공지능의 한 갈래입니다. (규칙을 사람이 코딩한 것도 AI지만 ML은 아님)

Q2 정형 · 반정형 · 비정형 데이터

데이터를 "행·열 표에 얼마나 잘 맞느냐"로 나눈 것입니다.



쉽게 — 정형=칸이 딱 정해진 **약통**(엑셀 표). 반정형=칸은 없지만 이름표가 붙은 **지퍼백**(JSON·XML). 비정형=이름표도 칸도 없이 상자에 쏟아부은 것(사진·녹음·줄글). 왼쪽일수록 바로 계산하기 쉽습니다.

유형	예	특징
정형	CSV, 엑셀(train.csv)	행·열 표 그대로 → 분석 쉬움
반정형	JSON, XML, 웹로그	이름표(태그·키)는 있으나 고정 표는 아님
비정형	사진, 음성, 자유 텍스트	구조 없음 → 전처리·딥러닝 필요

단골 함정 — 텍스트라고 다 비정형이 아닙니다. HTML·XML은 태그 구조가 있어 **반정형**, 순수 줄글(뉴스·리뷰)이 비정형. **CSV=정형, JSON=반정형**으로 기억!

Q3 지도학습 vs 비지도학습

쉽게 — 지도학습=답지가 붙은 문제집. 풀고 답을 맞춰 보며 배웁니다(정답 y가 있음). 비지도학습=답지가 아예 없음. 대신 "**비슷한 것끼리 알아서 묶어 봐**" — 숨은 무리를 발견하는 게 목적입니다.



지도=정답(색)을 보고 경계를 배움 / 비지도=색 없어도 가까운 것끼리 묶음.

Q4 분류 vs 회귀


지도학습은 **정답의 종류**에 따라 둘로 나뉩니다. **분류**=정답이 카테고리(그룹), **회귀**=정답이 연속된 숫자.

쉽게 — 분류는 객관식, 회귀는 주관식. 분류는 "생존?/사망?"처럼 보기 중에서 고르는 것(맞거나 틀리거나). 회귀는 "이 집 얼마?"처럼 숫자를 직접 적는 것(3.0억 정답에 3.1억이면 조금 빗나감).

주의 — 로지스틱 "회귀"는 이름과 달리 분류에 씁니다. 확률(연속값)을 계산한 뒤 0.5로 잘라 0/1로 나누기 때문이에요.

분류 실험실 — 경계선 긋기

파란 점(정상)과 빨간 점(스팸)이 한 줄에 섞여 있어요. 슬라이더로 **경계선**을 옮겨, 왼쪽=정상 · 오른쪽=스팸으로 나눠 보세요.



경계선 위치

55

정확히 나눈 비율

94%

거의 완벽하게 나뉘었어요 — 이렇게 경계로 가르는 게 분류입니다.

Q5 특성(X) · 타겟(y)

데이터는 보통 표(행=샘플, 열=속성)입니다. **특성 X**=예측에 쓰는 입력 열들, **타겟 y**=맞히려는 정답 열.

쉽게 — 가리고 맞추기 놀이. 표에서 정답 열 하나를 손으로 가리고, 나머지 열만 보고 그 값을 맞춥니다. 가린 열이 타겟 y, 보고 있는 나머지가 특성 X. 같은 표라도 무엇을 가리느냐로 문제가 달라져요.

나이 (X)	객실등급 (X)	성별 (X)	생존여부 (y)
22	3	남	0
38	1	여	1

독립변수 · 종속변수(같은 것의 통계 이름) — "공부시간 → 시험점수"에서 **원인=독립변수(X)**, **결과=종속변수(y)**. 독립변수는 여러 개라 대문자 X, 종속변수는 하나라 소문자 y로 씁니다.

Q6 변수의 척도 · 범주형 vs 수치형

특성은 측정 방식에 따라 **명목 → 순서 → 등간 → 비율** 4척도로 나뉩니다. "이 숫자로 어디까지 계산해도 되나"를 4단계로 나눈 것.

척도	예	할 수 있는 것
명목	등번호·색	이름표일 뿐, 비교·계산 금지
순서	등수·만족도	순서 비교 O, 뺄셈은 무의미
등간	온도(°C)	뺄셈 O, 배수(2배)는 X (절대 0 없음)
비율	키·무게	뺄셈·배수 모두 O (절대 0 있음)

쉽게 — '절대 0'은 '진짜 아무것도 없음'을 뜻해요. 0kg은 무게가 아예 없는 거라 20kg은 10kg의 **딱 2배**가 맞습니다(비율). 하지만 0°C는 '더위가 없음'이 아니라 그냥 눈금 하나라, 20°C가 10°C의 **2배 더위는 아니에요**(등간).

범주형 vs 수치형 — 명목·순서=범주형(글자) → 인코딩 필요. 등간·비율=수치형(숫자) → 스케일링 대상. pandas에서 `object` = 범주형, `int/float` = 수치형. 명목형은 **원핫**, 순서형은 순서를 살려 **라벨(정수)** 인코딩이 자연스럽습니다.

Q7 차원과 차원의 저주

머신러닝에서 **차원** = **특성(열, x)의 개수**. 열이 3개면 3차원, 30개면 30차원입니다. (행=샘플 수는 차원과 무관)

쉽게 — 키만 알면 1차원(줄 세우기), 키·몸무게면 2차원(종이에 점), 키·몸무게·나이면 3차원(공간에 점). 항목이 **30개면 30차원** — 그림으로 못 그립니다.

차원의 저주 — 특성이 너무 많으면 오히려 성능이 **나빠집니다**. 공간이 급격히 넓어져 데이터가 텅 빈 곳에 흩어지고("가까운 이웃"이 무의미), 과적합·계산량이 커져요. → 정보를 지키며 줄이는 **차원축소(PCA)**로 해결.

쉽게 — 반 친구 30명을 **키 하나**로 줄 세우면 내 옆에 비슷한 사람이 딱 붙어 있어요. 그런데 키·몸무게·성적·취미... **항목을 30개**나 보고 비교하면 '나랑 다 비슷한 사람'은 사실상 없어서 다들 멀찍이 떨어져 버립니다 — 그래서 '가까운 이웃'이 무의미해지는 게 차원의 저주예요.