

통계·전처리·학습

통계 기초·전체 워크플로우·전처리·과적합/누수·편향분산·fit/predict. **8~13**
절.

Q8 통계 · 확률 기초

이 절은 결국 세 가지 질문에 답하는 도구 모음입니다.



- ① 이 데이터, 한마디로 하면? → 가운데가 어디고(평균·중앙값), 얼마나 퍼졌고(표준편차), 어떤 모양인지(정규분포·박스플롯)
- ② 두 가지가 서로 관련 있나? → 상관계수
- ③ 이 차이, 진짜일까 우연일까? → 모집단·표본 · 가설검정 · p-value

대표값 — 평균 · 중앙값 · 최빈값

왜 중앙값? 연봉 [3000, 3200, 3500, 3800, 90000]의 평균은 20700(현실과 동떨어짐)이지만 **중앙값은 3500(대표성 있음)**. 그래서 결측치는 보통 중앙값으로 채웁니다.

정규분포 · 사분위수 · 박스플롯

정규분포 = 가운데(평균)에 물리고 양끝은 드문 종 모양. 박스플롯 = 분포를 크기순 4등분(사분위수)해, 가운데 50%(Q1~Q3)를 **상자**로, 정상 범위를 **수염**으로, 벗어난 값을 **점(이상치)**으로 그린 것.



박스 안 선=중앙값, 수염=정상 범위, 바깥 점=이상치(보통 $Q3 + 1.5 \times IQR$ 밖).

왜도(치우침) — 꼬리가 있는 쪽으로 평균이 끌려갑니다. 오른쪽 치우침이면 **평균 > 중앙값**(위 연봉 예). 그래서 치우친 데이터는 중앙값으로 대표하고, 심하면 `np.log1p`로 퍼 주기도 해요.

상관계수 · 가설검정 · p-value

상관계수(-1~1) = 두 변수가 함께 움직이는 정도. **모집단** = 알고 싶은 전체, **표본** = 실제로 뽑은 일부. 표본은 뽑을 때마다 달라져서(표본오차), 관측한 차이가 **진짜인지 우연인지** 헷갈립니다.


쉽게 — 상관계수는 '두 값이 손잡고 같이 움직이나'를 -1~1로 잰 것. 키가 클수록 몸무게도 크면 +(양의 상관), 하나가 커질 때 다른 게 작아지면 -(음의 상관), 아무 관계없으면 0.

가설검정 · p-value — 귀무가설(예: 두 그룹 평균이 같다)을 세우고, 데이터가 그 가정과 얼마나 안 맞는지를 **p-value**로 잭니다. p-value가 유의수준(보통 0.05)보다 **작으면 귀무가설 기각 = "차이가 통계적으로 유의"**. (빅분기 작업형3의 핵심)

쉽게 — **p-value** = '이 결과가 순전히 우연으로 나왔을 확률'이에요. 동전을 10번 던졌는데 앞면이 9번 나왔다고 해봐요. 동전이 공평하다면(이게 '귀무가설') 이런 일은 아주 드물죠 → 우연일 확률(p-value)이 작다 → "이 동전, 공평하지 않은 것 같다"고 의심하게 됩니다. p-value가 **0.05보다 작으면** 딱 그 상황 — **우연이라기엔 너무 드무니 '진짜 차이가 있다'**고 봅니다.

Q9 전체 워크플로우 (가장 중요)

지도학습 단원은 **아래 7단계를 그대로 반복** 합니다. 이걸 외우면 절반은 끝!



파랑(1~4)=데이터 준비, 초록(5~7)=모델링.

쉽게 — 시험 준비와 똑같아요. 로드=교재 사기 → EDA=훑어보기 → 전처리=밑줄 긋기 → 분할=모의고사용 문제 떼어 두기 → 학습=공부 → 평가=모의고사로 실력 확인 → 예측=실제 시험.

순서가 중요 — 정석은 **분할을 먼저** 하고 전처리. 스케일러·인코더 기준은 **train에서만 학습(fit)**하고 test엔 적용(transform)만. 여기서 **데이터 누수(11절)**가 생겨요.

Q10 전처리 — 모델이 먹을 수 있게 다듬기

쉽게 — 모델은 **계산기**예요. 빈칸을 넣으면 안 돌아가고(→ **결측치 채우기**), "빨강" 같은 글자도 못 먹고(→ **인코딩**), 숫자가 크면 무조건 중요하다고 착각합니다(→ **스케일링**).

손 볼 것	방법	메 모
결측치	수치형=중앙값, 범주형=최빈값	중앙값은 극단값에 강함
인코딩	명목=원핫, 순서=라벨(정수)	<code>pd.get_dummies</code> 한 줄
스케일링	표준화(평균0·표준편차1) / 정규화(0~1)	트리 계열은 불필요

흔한 실수 — `LabelEncoder` 는 입력 **X**가 아니라 **타겟 y** 전용. 입력 열엔 `OrdinalEncoder` / `OneHotEncoder` 를 쓰세요. 인코딩·스케일링 기준도 **train에서만 학습!**

Q11 분할 · 과적합 · 데이터 누수

쉽게 — 문제집 100문제를 다 풀어 보고 채점하면 당연히 100점(방금 답을 봤으니까). 그건 실력이 아니라 **기억**. 그래서 80문제만 공부하고 **20문제는 남겨 뒀다 시험** — 이게 분할입니다.


과적합=답을 통째로 외운 상태(본 문제는 다 맞지만 새 문제는 못 풀). **데이터 누수**=시험 문제를 미리 본 것(test 기준을 학습에 써 버림).

	train 점수	val 점수	진 단
과소적합	낮음	낮음	모델이 너무 단순
적정 (목표)	높음	높음(비슷)	두 점수가 가깝다
과적합	매우 높음	낮음	외운 것 — 차이가 큼

한 문장 — 점수 하나만 보면 셋을 구별 못 합니다. train 0.99만 보고 좋아하면 안 되는 이유 — val 점수와 나란히 놓기 전까진 실력인지 외운 건지 몰라요.

과적합 실험실 — 모델 복잡도

점들을 지나는 곡선의 **복잡도**를 바꿔 보세요. 너무 단순하면 대충 지나가고(과소적합), 너무 복잡하면 점을 다 통과하지만 새 데이터엔 약해요(과적합).



모델 복잡도

보통

훈련 점수 (공부한 문제) 새 데이터 점수 (진짜 실력)

89%

76%


점 다시 뽑기

딱 좋아요 — 훈련도 새 데이터도 높게 나옵니다(적정).


Q12 편향-분산 트레이드오프

앞의 과적합/과소적합을 설명하는 이론 틀. 오차 = 편향² + 분산 + 잡음.

쉽게 — 다트로 보면: 편향=거냥이 빠들어 늘 같은 쪽으로 빗나감(과소적합). 분산=던질 때마다 사방으로 흩어짐(과적합). 잡음=바람 — 조준·손이 완벽해도 어쩔 수 없이 빗나가는, 못 줄이는 오차.



저편향·저분산 (목표)



고분산 (과적합)

노란 중심=정답. 편향=치우침, 분산=흩어짐. 둘의 합(총오차)이 최소인 지점이 목표.

성능개선과 연결 — 정규화는 분산 ↓ (과적합 잡기), 앙상블에서 배깅=분산 ↓, 부스팅=편향 ↓. 그래서 편향-분산은 성능개선·앙상블의 뿌리입니다.

Q13 학습과 예측 — fit / predict / predict_proba

거의 모든 모델이 같은 사용법. 이 셋만 알면 모델이 바뀌어도 코드가 똑같아요.

쉽게 — `fit` = 공부, `predict` = 답 적기("답: 1"), `predict_proba` = 속마음까지("1 같긴 한데 80% 확신"). **확신도를 알면 기준선을 옮길 수 있어요** — 놓치면 큰일 나는 질병 검사면 "30%만 넘어도 일단 1"로 기준을 낮춥니다.